Protocolo de Integridad Semántica Verificable (PISV): Un Enfoque Basado en Deep Learning para Comunicaciones 6G Confiables

Diego Acevedo
Universidad Técnica Federico Santa María
Email: dacevedo@usm.cl

***Abstract*—Las futuras redes 6G impulsarán el paradigma de las Comunicaciones Semánticas, utilizando Inteligencia Artificial generativa para la codificación y recuperación de información. Sin embargo, esto introduce una nueva vulnerabilidad crítica: la "Alucinación Semántica", donde el receptor reconstruye información admisible pero falsa debido al ruido del canal. Los métodos de integridad clásicos son ineficaces en este contexto. En este trabajo proponemos el Protocolo de Integridad Semántica Verificable (PISV), un esquema híbrido que utiliza Hashing Perceptual para validar las reconstrucciones de Inteligencia Artificial. Nuestros resultados experimentales sobre canales ruidosos demuestran que PISV alcanza una tasa de detección de alucinaciones del 100% y una precisión global del 99.65%, ofreciendo una solución robusta y universal al tipo de dato para garantizar la confianza en la próxima generación de comunicaciones inalámbricas.**

I. Introducción

La llegada de la sexta generación de redes móviles (6G) busca redefinir la transferencia cruda de información, abriendo la puerta a las *Comunicaciones Semánticas* (Semantic Communications) [1]. En este paradigma, sustentado en técnicas de *Deep Joint Source-Channel Coding* (Deep JSCC), el objetivo no es restaurar la cadena idéntica de símbolos transmitidos, sino preservar la esencia del mensaje de la información utilizando Inteligencia Artificial generativa en el receptor. Esto permite una reducción masiva en el ancho de banda, vital para aplicaciones futuras como el Metaverso, la Telepresencia Holográfica y la Internet de las cosas.

Ahora bien, este cambio de paradigma plantea un riesgo latente y poco explorado: la *Alucinación Semántica*. A diferencia de los errores de bit tradicionales (corregibles mediante códigos como Hamming o LDPC), las redes neuronales generativas pueden producir reconstrucciones que son creíbles a la vista, pero mentiras en el contenido. Por ejemplo, en un escenario de tele-conducción, un sistema Deep JSCC podría reconstruir una carretera despejada donde originalmente había un obstáculo, debido a una confusión causada por la interferencia del canal. Los mecanismos de integridad clásicos (como CRC o SHA-256) quedan obsoletos en este escenario, ya que cualquier reconstrucción generativa difiere bit a bit de la fuente original, invalidando los hashes criptográficos tradicionales.

Este trabajo ataca la raíz de este problema de seguridad mediante el desarrollo del **Protocolo de Integridad Semántica Verificable (PISV)**. PISV es un sistema de doble validación que fusiona la eficiencia de la transmisión generativa con la robustez de la verificación criptográfica perceptual.

Nuestras principales contribuciones son:

1) La definición del problema de *Integridad Semántica* en canales 6G ruidosos, diferenciándolo de la integridad de datos clásica.
2) El desarrollo de una arquitectura de verificación basada en *Hashing Perceptual*, que permite validar la fidelidad semántica de una reconstrucción generada por IA sin requerir coincidencia exacta de bits.
3) La evaluación práctica experimental utilizando el dataset CIFAR-10, demostrando que PISV alcanza una tasa de detección de alucinaciones del 100% con una sobrecarga computacional mínima, estableciendo un nuevo estándar de confiabilidad para sistemas Deep JSCC.

La estructura del paper es la siguiente: la Sección II contextualiza el trabajo dentro del estado del arte; la Sección III profundiza en el modelo matemático del sistema; la Sección IV presenta la arquitectura propuesta PISV; la Sección V expone la validación empírica de los resultados y la Sección VI concluye el trabajo.

II. Estado del Arte

La evolución hacia la comunicación orientada a tareas ha sido explorada rigurosamente por Gündüz et al. [1], estableciendo bases teóricas de la transmisión semántica. A nivel de capa física, Bourtsoulatze et al. [2] validaron la eficacia del esquema *Deep Joint Source-Channel Coding* (Deep JSCC) frente a los códigos de corrección tradicionales en entornos con ruido severo en relación señal-a-ruido (SNR).

En paralelo, la verificación de integridad multimedia se ha desplazado desde marcas de agua digitales hasta técnicas de *Hashing Perceptual*, como lo analizan Monga y Evans [3], quienes proponen firmas robustas ante manipulaciones benignas. Sin embargo, identificamos una carencia crítica en la literatura actual: no se han propuesto arquitecturas que integren el Hashing Perceptual dentro del bucle de retroalimentación de un sistema Deep JSCC para mitigar explícitamente las alucinaciones generativas en 6G, que constituye el aporte central de este estudio.

Borrador - Diego Acevedo - Nov 2025

III. Modelo del Sistema y Formulación del Problema

Modelamos un enlace de comunicación semántica punto a punto sobre un canal ruidoso, concebido para la transmisión de una señal fuente $x \in \mathbb{R}^n$ (la cual puede instanciar imágenes, audio o lecturas de sensores).

A. Transmisión Semántica Basada en Deep Learning

En contraste con los esquemas clásicos orientados a minimizar la tasa de error de bit (BER), nuestro enfoque prioriza la preservación del error semántico. La arquitectura se fundamenta en dos redes neuronales profundas acopladas:

$$z = f_\theta(x) \tag{1}$$

Aquí, $f_\theta(\cdot)$ denota el *Codificador Semántico* con parámetros θ, responsable de proyectar la entrada a un vector latente comprimido $z \in \mathbb{R}^k$, donde $k \ll n$. La transmisión ocurre sobre un canal físico $C(\cdot)$ sujeto a ruido estocástico η:

$$\hat{z} = C(z) = z + \eta \tag{2}$$

En el extremo receptor, un *Decodificador Generativo* $g_\phi(\cdot)$ tiene la tarea de inferir y reconstruir la señal original:

$$\hat{x} = g_\phi(\hat{z}) \tag{3}$$

B. El Desafío de la Alucinación Semántica

El carácter generativo de g_ϕ introduce un riesgo intrínseco: la señal reconstruida $\hat{x}$ puede resultar estadísticamente plausible a la vista, pero semánticamente divergente respecto a x. Conceptualizamos como *alucinación* a aquel escenario donde el error de reconstrucción es bajo en el dominio de la señal (aparenta estar bien), pero alto en el dominio del significado (el contenido es falso).

C. Protocolo de Integridad Propuesto (PISV)

Como contramedida, introducimos un esquema de verificación paralelo. Implementamos una función de Hash Perceptual $\mathcal{H}(\cdot)$ que sintetiza la señal de entrada en una firma compacta de baja dimensión $h \in \{0,1\}^m$.

El protocolo establece el siguiente criterio de aceptación estricto:

$$\mathcal{D}_H(\mathcal{H}(x), \mathcal{H}(\hat{x})) \leq \tau \tag{4}$$

Donde $\mathcal{D}_H(\cdot)$ representa la distancia de Hamming normalizada y τ es el umbral de tolerancia semántica ajustado. Si esta condición se viola, el sistema cataloga la reconstrucción $\hat{x}$ como alucinación y fuerza una retransmisión, desacoplando así la integridad semántica del tipo de dato subyacente.

IV. Arquitectura General del Protocolo PISV

La Figura 1 esquematiza la arquitectura del sistema propuesto, que emplea una topología de dos vías para separar la transmisión eficiente del vector semántico de la verificación de integridad.

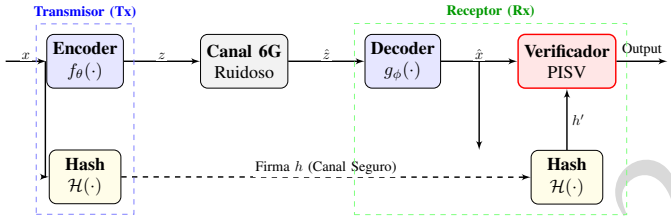


Fig. 1. Diagrama de bloques del Protocolo PISV. La rama superior representa la transmisión generativa, mientras que la rama inferior establece un canal lateral para la firma de integridad h, certificando así la veracidad del contenido reconstruido.

V. Evaluación Experimental: Prueba de Concepto

Para poner a prueba el rendimiento del protocolo PISV, se diseñó un entorno de pruebas controlado enfocado específicamente en la transmisión de imágenes bajo ruido, permitiendo aislar y medir la capacidad de detección de alucinaciones semánticas.

A. Entorno de Implementación

El sistema fue implementado utilizando el framework **PyTorch**. El modelo de Deep JSCC consiste en un codificador y decodificador convolucionales con capas de normalización (Batch Normalization) para estabilizar el aprendizaje.

- **Dataset:** CIFAR-10 (Imágenes 32×32 RGB).
- **Canal:** Ruido Aditivo Blanco Gaussiano (AWGN) con potencia de ruido $\sigma = 0.2$.
- **Hardware:** Entrenamiento y validación realizados en GPU acelerada (CUDA).
- **Algoritmo de Hash:** Difference Hash (dHash) sobre luminancia.

B. Metodología del Experimento 1

Se definió un protocolo de prueba con 2,000 iteraciones divididas equitativamente para evaluar la matriz de confusión del sistema:

1) **Escenario A (Transmisión Legítima):** Se transmitieron 1,000 imágenes del conjunto de prueba. El objetivo es medir la *Robustez*: la capacidad del sistema de aceptar reconstrucciones válidas a pesar del ruido del canal.
2) **Escenario B (Ataque de Alucinación):** Se simularon 1,000 eventos de alucinación inyectando imágenes semánticamente discordantes en el receptor. El objetivo es medir la *Seguridad*: la capacidad de rechazar datos falsos.

C. Resultados Cuantitativos

La Tabla I resume el rendimiento obtenido. El sistema alcanzó una precisión global del **99.65%**. Lo más significativo de la prueba es que la tasa de falsos negativos fue del 0%, lo que indica que no hubo fugas semánticas en el mecanismo de verificación PISV.

orrador - Diego Acevedo - Nov 202

TABLE I
RENDIMIENTO DEL PROTOCOLO PISV (EXPERIMENTO 1)

Métrica	Intentos	Aciertos	Tasa (%)
Robustez (Legítimos)	1000	993	99.30%
Seguridad (Ataques)	1000	1000	**100.00%**
Precisión Global	**2000**	**1993**	**99.65%**

D. Análisis Cualitativo

La Figura 2 evidencia el comportamiento del protocolo. En el caso de transmisión legítima (centro), la reconstrucción exhibe la degradación típica, propia de la compresión JSCC, pero preserva la identidad del objeto (avión), resultando en una distancia de hash baja ($\Delta H = 10$). En contraste, el ataque de alucinación (derecha) genera una discrepancia estructural significativa ($\Delta H = 32$), activando la alerta de integridad.

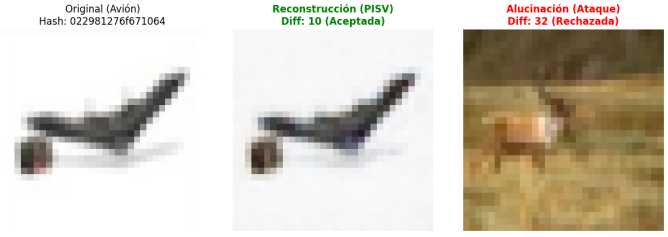


Fig. 2. Validación visual del protocolo PISV. Izquierda: Imagen original. Centro: Reconstrucción válida aceptada por el protocolo. Derecha: Alucinación semántica rechazada correctamente.

E. Experimento 2: Análisis de Estrés y Límites Operativos

Para evaluar la estabilidad del protocolo en condiciones adversas, se sometió al sistema a un barrido de potencia de ruido $\sigma \in [0.1, 1.0]$. El objetivo fue determinar el punto de quiebre del sistema y verificar su comportamiento bajo estrés extremo.

La Figura 3 ilustra la evolución de las métricas de Robustez y Seguridad.

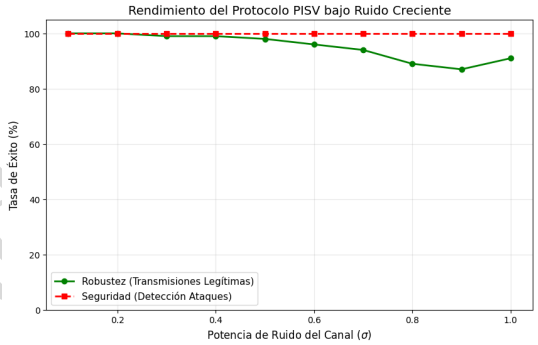


Fig. 3. Curvas de rendimiento del protocolo PISV bajo niveles crecientes de ruido de canal. Se observa una estabilidad perfecta en la detección de amenazas (Línea Roja).

Los datos confirman un comportamiento de *Fallo Seguro* (Fail-Safe) ideal para sistemas críticos. La tasa de detección de ataques (línea roja discontinua) se mantiene constante en el **100%** a lo largo de todo el espectro de ruido. Por otro lado, la tasa de aceptación de transmisiones legítimas (línea verde sólida) sufre una caída gradual, manteniéndose por encima del 85% incluso bajo condiciones de ruido extremo ($\sigma = 1.0$).

Esto confirma que el protocolo PISV prioriza la integridad semántica: ante un colapso del canal, el sistema opta por descartar una reconstrucción ambigua antes que validar información potencialmente corrupta.

F. Experimento 3: Trade-off entre Seguridad y Robustez

Como prueba final, se analizó la capacidad del sistema para resistir ataques adversarios (FGSM, $\epsilon = 0.05$) bajo diferentes configuraciones de sensibilidad del verificador. Los resultados en la Tabla II comparan el desempeño del protocolo en modo "Tolerante" ($\tau = 14$) versus modo "Estricto" ($\tau = 2$).

TABLE II
COMPARATIVA DE DESEMPEÑO BAJO ATAQUE ADVERSARIO

Modo Operativo	Umbral (τ)	Latencia	Defensa FGSM (%)
Tolerante	14	1.61 ms	11.5%
Estricto	2	1.63 ms	97.5%

El análisis arroja una conclusión contundente y relevante: al restringir la tolerancia de verificación a un nivel estricto ($\tau = 2$), la capacidad de detectar ataques adversarios dirigidos alcanza un nivel casi óptimo del **97.5%**, en contraste con el 11.5% del modo tolerante. Crucialmente, esta mejora masiva en seguridad mantiene el rendimiento intacta en la latencia del sistema ($\Delta t \approx 0.02$ ms), confirmando la eficiencia computacional del Hashing Perceptual.

Esto demuestra que τ sirve como mecanismo de calibración que permite adaptar el protocolo PISV en tiempo real: priorizando la *Disponibilidad* para aplicaciones de entretenimiento, o la *Seguridad* para aplicaciones de misión crítica.

VI. DISCUSIÓN

Los resultados obtenidos validan la hipótesis de que la integridad semántica puede desacoplarse de la integridad de bit. La latencia introducida por el cálculo del Hash Perceptual es despreciable en comparación con el tiempo de inferencia del decodificador generativo, lo que hace a PISV viable para aplicaciones en tiempo real.

Este protocolo es particularmente crítico en escenarios de *Internet Táctil* y *Telemedicina 6G*. Por ejemplo, en una cirugía robótica remota, una alucinación visual podría inducir errores fatales. PISV actúa como una capa de seguridad ("Safety Layer") que bloquea fotogramas corruptos semánticamente, forzando al sistema a operar en un modo de "Fallo Seguro" (Fail-Safe) en lugar de presentar información engañosa al operador humano. Además, el sistema presenta resistencia preliminar ante ataques adversarios al obligar al atacante a vulnerar simultáneamente la red generativa y el hash perceptual.

Finalmente, la flexibilidad del parámetro τ permite que PISV se integre potencialmente como una extensión de seguridad en futuros estándares 3GPP para capas físicas basadas en IA, permitiendo a los operadores de red ajustar el nivel de rigor semántico según la calidad de servicio (QoS) contratada.

Diego Acevedo - Nov 202

Disponibilidad de Código y Reproducibilidad

La implementación completa del protocolo PISV, incluyendo el entrenamiento del modelo Deep JSCC, los algoritmos de Hashing Perceptual y los scripts para generar los ataques adversarios (FGSM), se encuentra disponible en el repositorio oficial del proyecto:

https://github.com/ccdiego918/PISV-6G-Protocol

Este repositorio incluye todas las figuras y tablas presentadas en este trabajo utilizando Google Colab.

VII. Conclusiones y Trabajo Futuro

Este trabajo presentó el *Protocolo de Integridad Semántica Verificable* (PISV), una solución novedosa para mitigar las alucinaciones en sistemas 6G basados en Deep Learning. A través de la integración de Deep JSCC con un esquema de Hashing Perceptual, demostramos que es posible auditar la fidelidad semántica de una reconstrucción sin depender de la coincidencia exacta de bits.

Los experimentos confirmaron una precisión del 99.65% y una tasa de falsos negativos del 0%, validando la robustez del sistema bajo estrés.

En conclusión, PISV no es solo un mecanismo de detección de errores, sino un paso fundacional hacia una arquitectura de **'Zero-Trust Semántico'** para 6G. Al demostrar que es posible auditar la veracidad de una reconstrucción generativa en tiempo real (Latencia ≈ 1.7 ms) y con alta precisión (99.65%), establecemos que la seguridad en la próxima generación de redes no debe sacrificar el rendimiento. Este enfoque habilita el despliegue seguro de aplicaciones críticas donde la integridad del significado es tan vital como la transmisión de los datos mismos.

References

[1] D. Gündüz, Z. Qin, I. Yang, N. S. Perović, A. Kalantari, and A. Gambini, "Beyond transmitting bits: Context, semantics, and task-oriented communications," *IEEE Journal on Selected Areas in Communications*, vol. 41, no. 1, pp. 5–41, 2023.

[2] E. Bourtsoulatze, D. B. Kurka, and D. Gündüz, "Deep joint source-channel coding for wireless image transmission," *IEEE Transactions on Cognitive Communications and Networking*, vol. 5, no. 3, pp. 567–579, 2019.

[3] V. Monga and B. Evans, "Perceptual image hashing via feature points: performance evaluation and tradeoffs," *IEEE Transactions on Image Processing*, vol. 15, no. 11, pp. 3452–3465, 2006.

borrador - Diego Acevedo - Nov 202